

시각 경험 재사용의 실패 지점

VLM 에이전트 시각 기억 연구 — 전체 실험 보고서


한 문장 요약

시각 기억(KV)을 일부만 남기는 압축의 실패는 저장 시점에는 예측 불가능하지만
(선택 규칙 9종 $\times$ 3도메인 $\times$ 2모델 전패, 천장과 +39~61%p),
읽기 시점에는 감지 가능하며(첫 답 토큰 확신도 AUROC 0.73~0.81),
장기 보관의 정답은 KV가 아니라 압축 이미지다
(32KiB 사진이 100배 큰 KV 조각보다 높은 유지율 0.95~0.98).

증거 등급 표기 — [승격]: 동결 프로토콜·신규 표본 [파일럿]: 탐색 측정
[계약/기제/스모크]: 구현 검증·합성 인과·소표본

1. 실패의 법칙 — 유지율은 근거 이동 거리에 단조 감소한다

[승격] 신규 표본, 5% 예산, 원본-정답 조건부 · 8회 재현 (2모델×2도메인×파일럿/승격)




읽는 법

- 새 질문의 근거가 옛 질문과 같은 자리면 거의 안 무너지고(0.54~0.87), 다른 자리면 무너진다(0.25~0.53) — 네 조건 모두 예외 없이 한 방향.
- 원인: 지운 자리의 정보는 물리적으로 없다. 실패가 '근거 겹침'이라는 변수 하나로 환원되므로, 뒤의 감지 방법(6쪽)이 성립한다.
- 관련 승격 수치: 재사용 붕괴(자기-전이) GUI +59.4pp [55.0,63.6], 자연 +24.5pp [20.2,28.8].

2. 천장 격차 — 어떤 선택 규칙도, 어떤 예산도 못 닫는다

[파일럿] GUI 예산 곡선(1~40%) + [승격] KVzip 원저 점(★) · 조건부 유지율




읽는 법

- 질문을 미리 보면(파란 천장) 1% 예산으로도 0.80 — 용량은 문제가 아니다.
- 원저 KVzip(★)이 현실 규칙 중 최강이지만 5%에서 천장과 +38.8pp [승격], Qwen3에서는 +48.0pp. 절반(40%)을 남겨도 격차 +15pp가 남는다.
- 결론: 병목은 알고리즘이 아니라 '미래 질문을 모른다'는 정보 부족 — 선행연구 SSF(2607.25467)도 동일 현상을 독립 보고 (진단의 외적 타당성).

3. 승격 재현 — 동결 프로토콜·신규 표본에서 전 항목 방향 유지

[승격] 16라운드 (2모델×2도메인×4실험), 오차막대 = 이미지 cluster bootstrap 95% CI




읽는 법

- 규칙(표본·seed·판정 기준)을 실행 전에 동결하고, 한 번도 안 쓴 화면 472장에서 재측정.
- 여섯 대비 모두 파일럿과 같은 방향, 비슷한 크기 — '탐색 과정의 우연'이 아니라는 검증.
- held-out은 seed 3개로 반복: GUI pool 우위 +17.0/+14.8/+20.6 (전부 CI가 0 제외).
- 한계 기재: GUI 신규 표본은 적격 풀 소진으로 172화면(목표 300 미달). 두 모델 모두 Qwen 계열.

4. 도메인 3체제 — '무엇이 통하는가'는 근거 분포가 정한다

[파일럿+승격] 5% 예산 · 무작위 바닥과 pool 가치의 체제 이동





읽는 법

- 문서: 근거가 흩어짐 → 무작위도 경험도 무력 (범용 신호가 유일한 지푸라기).
- GUI: 근거가 소수 영역에 집중 → 과거 이력·KVzip이 통함. 원저 3b 결과도 일치: KVzip은 GUI 최강(0.542)이지만 자연에선 무작위 동급(0.537 vs 0.540) [승격].
- 자연: 중복성이 높아 뭘 남겨도 비슷 — 단, 모델에 따라 경계가 이동 (Qwen3는 무작위에 덜 관대 → 자연에서도 pool이 +22pp로 유의해짐).
- 의미: 고정된 압축 정책 하나는 어느 체제에선가 반드시 실패한다.

5. 실패는 감지된다 — 확신도 신호와 운영 곡선

[파일럿+승격] AUROC(왼쪽) · 캐스케이드 정확도-지연(오른쪽, GUI 신규 257질문)




읽는 법

- 감지 원리: 근거를 잃은 모델은 첫 답 토큰부터 머뭇거린다(1·2등 점수차 축소).
이 값은 어차피 하는 계산의 부산물 — 추가 비용 0, 훈련 불필요.
- 임계값 하나(τ)가 모델·도메인을 건너 통했고(28~59% 폴백 밴드), 신규 표본 재보정도 근소 이동(1.914→2.094) — '한 번 보정으로 어디서든'.
- 운영 곡선: τ 만 돌리면 0.69@1.29s ~ 0.76@1.52s — 재읽기 정확도의 87%를 68% 비용에.
- 정정 기록: 초안 재활용 1단은 EOS 미검증 등 결함 + VeriCache 선점 → 보조로 강등.

6. 저장 크기의 진실 — KV는 이미지를 작게 저장하는 수단이 아니다

[계약] 원본-차단·실측 파일 byte (3장 관문 → 472장 확대 일치) · 로그 눈금




읽는 법

- 전체 KV는 원본 이미지의 752배, '압축했다'는 5% KV도 35배 — 저장 절약이라는 통념과 정반대. KV의 진짜 가치는 재계산 생략(첫 응답 20배 단축, SSD 로드 40ms)뿐.
- 극단의 반대편: OCR 텍스트는 원본의 1.2% 크기로 관문 6문항 중 6문항 유지.
- 시스템 귀결: 영구 보관 = 압축 사진(+텍스트 색인), KV = 자주 쓰는 것만 만드는 소모성 가속 캐시 — 서빙 시스템(AttentionStore·LMCache)의 전체-KV 연속과 구분.

7. 대표 결과 — 같은 저장량이면 무엇이 미래 질문을 지키는가

[스모크→확대] 472장 실데이터 · x=실제 저장 KB(로그), y=원본-정답 조건부 유지율





읽는 법

- 32KB 압축 사진(파랑/주황)이 유지율 0.95~0.98 — 100배 큰 KV 조각(빨간 ★, 0.54~0.62)을 압도. '무엇으로 저장?'의 답이 사진임을 규모 있는 실데이터로 확정.
- GUI의 최소 안전 예산은 8~32KB 사이(8KB엔 화면 절반이 안 들어감 — 정직 기재), 자연 사진은 8KB로도 0.84~0.86. 임베딩(노란 ▲)은 무손실이나 8.6MB — 저장용 아님.
- 남은 열: OCR 텍스트(실행 중) · 전체 KV 원본차단판(밤샘 실행) — 완성 시 본 그림 갱신.

8. 새로 열린 두 축 — 시간(낮음)과 행동

[기제] 합성 통제 실험 — 원본 차단·시스템콜 감사 통과·인과적 검증 단계



읽는 법

- D4: 낡은 기억의 실패는 '모르겠다'가 아니라 확신에 찬 과거 답(16/16) — 압축에서 발견한 '조용한 실패'가 시간 축에도 존재. 버전 관리·무효화가 필수 부품.
- D5: '기억이 있다'와 '기억으로 행동한다' 사이가 갈라짐 — 무엇을 누를지는 알지만 어디를 누를지(좌표)는 실패. 단, 기본 모델의 좌표 능력 통제 실험이 보완 필요(설계 리뷰 ⑤).
- 등급 주의: 합성 통제 실험 — 실데이터 discovery로 승격 전이며 일반화 주장 불가.

9. 실험 대장 요약 · 정정 · 다음 단계

정직성 기록 포함 — 실패·정정도 대장에 남김

단계	실험 수	핵심	등급
0. 측정 신뢰	4건	NaN 근본해결 · V1 누출 4배 · 직렬화 왕복	[계약]
1. 문서 파일럿	5건	격차 38pp · 붕괴 40pp · pool 과적합	[파일럿]
2. GUI·자연 확장	6건	단조 법칙 · 3체제 · NO-MEM · 가짜상관 함정	[파일럿]
3. 방법 후보	7건	감지 AUROC · 비용 실측 · Qwen3 재현 · 예산격자	[파일럿]
4. 승격	6건	16라운드 방향 유지 · R2 gate · 원저 3b	[승격]
5. 검토·정정	3건	SSF·VeriCache 선점 확인 · 초안 보증 과장 정정	[정정]
6. 진단 프로그램	7건	원본차단 저울 · 시간·행동 축 · 설계 리뷰 8건	[계약~기제]
7. D1 본 시험	4건	사진 곡선 완료 · 임베딩 완료 · OCR/KV 진행	[확대 중]

정직성 기록

- 정정 1: 초안 재활용의 '출력 동일 보증'은 과장 (EOS 미검증 — 접두 일치까지만).
- 정정 2: '범용 신호는 GUI에서 해롭다'는 우리 적응판 한정 — KVzip 원저는 GUI 최강.
- 선점 확인: 진단 현상(SSF, 26.07) · 압축-draft 검증(VeriCache, 26.05) — 관련연구 재배포.
- 실측 상한: 마스크 시뮬레이션은 실제 재로드보다 +5%p 후함 → 시스템 수치는 재로드 기준.

다음 단계

- 1) D1 본 시험 완성 (OCR 텍스트·전체 KV 열 — 실행 중, 완료 시 7쪽 그림 갱신)
- 2) 설계 리뷰 8건 반영 (질문 감사 · 텍스트 예산 곡선화 · 자기호환 통제 · 표본 조달 등)
- 3) 병목 확정 후 Method 선택 (진단 프로그램 § 8의 대응표) → 사전등록 M7 confirmation
- 4) 논문: 진단 장(승격 완료 수치) + substrate frontier + 시스템 가설 — 프레임 확정은 병목 이후