

시각 경험 재사용의 실패 지점


요약

모델이 이미지를 처리하며 만드는 내부 캐시(KV cache)의 일부만 남기는 압축은, 어떤 선택 규칙을 쓰든 '질문을 미리 아는 이상적 선택' 대비 +39~61%p 낮다 (2개 모델 × 3개 데이터 유형 전부). 다만 실패 여부는 답변 첫 토큰의 확신도로 사후 감지할 수 있다(AUROC 0.73~0.81). 장기 보관에는 KV cache보다 32KiB 압축 이미지가 유리하며(정답 유지율 0.95~0.98), 그 위에 저장·갱신·조회 규칙을 얹은 무학습 시스템은 전체 보관 대비 97.4%의 정확도를 44%의 저장량으로 달성하고, 화면 갱신 후 이전 값을 답하는 오류 (48/48건 발생)를 제거한다.

증거 등급 표기 — [확증]: 절차를 사전 동결한 뒤 새 표본에서 재현 [탐색]: 예비 측정
[검증/통제/소표본]: 구현 검증 · 합성 화면 통제 실험 · 적은 표본 [사전등록]: 성공 기준을 실행 전 고정

1. 성능은 질문 근거의 위치에 따라 단계적으로 하락한다

[확증] 신규 표본 · KV 5%만 보존 · 원본에서 맞힌 문항 기준 · 8회 반복 재현 (2모델×2데이터 유형)




읽는 법

- 새 질문의 근거 영역이 이전 질문과 같으면 성능이 유지되고(0.54~0.87), 다른 영역이면 크게 하락한다(0.25~0.53) — 네 조건 모두 예외 없이 같은 방향.
- 원인: 삭제한 영역의 정보는 남아 있지 않다. 실패가 '근거 영역이 겹치는가' 하나로 설명되므로, 이후의 실패 감지 방법(5번 그림)이 성립한다.
- 관련 수치: 같은 질문 대비 새 질문의 정확도 하락 GUI +59.4%p [95% CI 55.0,63.6], 자연 +24.5%p [20.2,28.8].

2. 이상적 선택과의 격차 — 어떤 규칙·보존 비율로도 닫히지 않는다

[탐색] GUI, 보존 비율 1~40% + [확증] KVzip 공식 구현(★) · 원본에서 맞힌 문항 기준




읽는 법

- 질문을 미리 알면(파란 선) 1%만 보존해도 0.80 — 저장 용량 자체는 병목이 아니다.
- 공개 구현 중 가장 강한 KVzip(★)도 5% 보존에서 이상적 선택보다 +38.8%p 낮고 (Qwen3-VL에서는 +48.0%p), 40%를 보존해도 +15%p 격차가 남는다.
- 결론: 병목은 선택 알고리즘이 아니라 '미래의 질문을 알 수 없다'는 정보 제약이다. 같은 현상을 독립적으로 보고한 선행연구(SSF, arXiv 2607.25467)와 일치한다.

3. 확증 재현 — 절차를 미리 고정하고 새 표본에서 같은 결과

[확증] 16회 반복 (2모델×2데이터 유형×4실험) · 오차막대 = 이미지 단위 bootstrap 95% 신뢰구간




읽는 법

- 표본·난수·판정 기준을 실행 전에 문서로 고정하고, 사용한 적 없는 화면 472장에서 재측정.
- 여섯 지표 모두 탐색 단계와 같은 방향·비슷한 크기 — 탐색 과정의 우연이 아님을 확인.
- 학습에 쓰지 않은 질문 검증은 난수 3종으로 반복; +17.0/+14.8/+20.6 (신뢰구간 모두 0 제외).
- 남긴 한계: GUI 신규 표본은 조건에 맞는 화면 소진으로 172장(목표 300장 미달).
- 두 모델 모두 Qwen 계열이라 타 계열 일반화는 미검증.

4. 데이터 유형별 차이 — 효과적인 전략은 근거의 분포가 정한다

[탐색+확증] KV 5% 보존 기준 · 유형별로 통하는 선택 규칙이 다르다





읽는 법

- 문서: 근거가 넓게 흩어져 있어 무작위 선택도 과거 이력도 효과가 없다.
- GUI: 근거가 소수 영역에 집중 → 과거 이력과 KVzip이 효과적. KVzip은 GUI에서 가장 강하지만(0.542) 자연 이미지에선 무작위와 동급(0.537 vs 0.540) [확증].
- 자연: 정보 중복이 커서 무엇을 남겨도 비슷 — 단 경계는 모델에 따라 이동 (Qwen3-VL은 자연에서도 과거 이력 이득이 +22%p로 유의).
- 의미: 하나의 고정된 압축 정책은 어느 유형에선가 반드시 실패한다.

5. 실패는 사후 감지할 수 있다 — 답변 확신도와 정확도-지연 곡선

[탐색+확증] 감지 성능(왼쪽) · 단계적 재시도의 정확도-지연 (오른쪽, GUI 신규 257질문)




읽는 법

- 원리: 근거를 잃은 모델은 답변 첫 토큰의 1·2순위 확률 차이가 작아진다.
이 값은 생성 과정의 부산물이라 추가 계산도 훈련도 필요 없다.
- 임계값 하나가 모델·데이터 유형을 건너 유효했고, 새 표본 재보정에서도 값이 거의 유지됐다(1.914→2.094).
- 곡선: 임계값 조절만으로 0.69@1.29초 ~ 0.76@1.52초 — 원본 재입력 정확도의 87%를 68%의 지연으로 얻는다.
- 정정 기록: 이전 답 재활용 방식은 종료 토큰 미검증 결함과 선행연구(VeriCache) 중복이 확인되어 보조 수단으로 내렸다.

6. 저장 크기 비교 — KV cache는 저장 용량을 줄이는 수단이 아니다

[완료] 원본 접근 차단 · 실측 파일 크기 — 472장 표본 · 로그 눈금




읽는 법

- 전체 KV는 원본 이미지 파일의 752배, 5%만 남겨도 35배 — 저장을 절약한다는 통념과 정반대다. KV의 가치는 저장이 아니라 재계산 생략(첫 응답 20배 단축)에 있다.
- 반대 극단: 문자 인식 텍스트는 원본의 1.2% 크기로 검사 6문항 전부 유지.
- 결론: 영구 보관은 압축 이미지(+텍스트 색인)로, KV는 자주 쓰는 항목만을 위한 소모성 캐시로 — 역할이 나뉜다.

7. 같은 저장량에서 무엇이 미래 질문에 가장 잘 답하는가

[완료] 실제 이미지 472장 · 가로축=실측 저장 크기(KB, 로그) · 세로축=원본에서 맞힌 문항의 유지율




읽는 법

- 32KB 압축 이미지(파랑/주황)가 유지율 0.95~0.98로, 100배 큰 5% KV(빨간 ★, 0.54~0.62)를 크게 앞선다 — '무엇으로 저장할 것인가'의 답은 이미지.
- GUI 화면의 최소 안전 용량은 8~32KB 사이(8KB에는 화면의 절반이 압축 자체가 불가). 자연 사진은 8KB로도 0.84~0.86. 임베딩(노란 ▲)은 무손실이지만 8.6MB.
- 임베딩·KV(우측 무손실 점)는 이미지의 240~2,000배 크기 — 저장용이 아니라 속도용.
- 텍스트(청록 ■)는 GUI에서 1.8KB로 기준의 80%를 내지만 자연에선 0.14로 무너진다.

8. 시간 축의 실패 — 화면이 갱신된 뒤 이전 값을 답한다

[통제] 합성 화면 통제 실험 — 원인을 분리하기 위한 단계 (실제 데이터 일반화 주장 아님)




읽는 법

- 화면이 갱신된 뒤 이전 화면의 기억만 주면, 모델은 '모른다'가 아니라 갱신 전 값을 그대로 답한다(16/16) — 오답이 정답처럼 보이는 위험한 형태의 오류.
- 행동 실험: 무엇을 클릭할지는 알지만(8/8) 화면 좌표를 짚는 것은 실패(0/8) — 능력이 분리된다. 기본 모델의 좌표 능력 통제는 보완 예정.
- 주의: 합성 화면 통제 실험 — 원인 분리가 목적이며 실제 데이터 일반화 주장은 아니다.

9. 저장 용량의 차등 배분 — 화면마다 필요한 용량이 16배 다르다

[탐색+정정] 실측 곡선 472장 재분석 · 같은 총용량을 나누는 세 방식 비교 (교차검증)






읽는 법

- 총용량이 빠듯한 구간(GUI, 화면당 8KB)에서만 차등 배분이 균등 배분을 +67% 앞서고 (0.261→0.433) 이상적 배분(0.436)에 도달한다. 용량이 충분하면 차이가 사라진다.
- 정정(재검증으로 확인): 이득의 원천은 예측 모델이 아니라 '이 화면은 8KB에 압축되지 않는다'는, 압축을 시도하면 무료로 얻는 정보다. 글자 수 신호의 추가 기여는 +0.003뿐.
- 자연 이미지의 남은 격차(+5.2%p)는 어떤 이미지 기반 신호로도 회수되지 않았다 (12번 그림) — 필요 용량이 이미지가 아니라 어떤 질문이 오는가에 달려 있기 때문.

10. 갱신 감지와 부분 갱신 — 이전 값 응답 오류의 해결

[통제·준실험환경] 합성 64세트 GPU 실측 + 브라우저 렌더 120쌍 (스크롤 포함)




부분 갱신 = 변경된 행만 잘라 저장
(JPEG, 평균 6.4KB)
정확도 0.000 → 1.000
이전 값 응답 0/32 · 저장량 -70.4%

읽는 법

- 기억이 한 장이면 모델은 그것이 오래된 것인지 알 수 없어 32/32건 갱신 전 값을 답한다 (누적 48/48). 두 시점을 함께 주면 전부 최신 값을 선택 — 문제의 위치는 모델이 아니라 기억을 갱신하지 않은 시스템 쪽이다(촬영 시각 표기를 함께 주는 것이 조건).
- 픽셀 비교 감지기(장당 30ms, CPU)가 96쌍 전부에서 변경 여부와 위치를 맞혔고, 결합하면 정확도 1.000. 이미지를 1/10로 압축해도 동일.
- 스크롤로 화면이 밀리면 단순 픽셀 비교는 무력해진다(감지 성능 0.44~0.49). 화면의 고정 영역(머리말)을 제외 → 세로 이동량 추정(오차 0.5px 이하) → 픽셀 비교 순서로 모든 조건 복구(89ms). 제외를 먼저 하지 않으면 이동량 추정 자체가 실패한다.
- 한계: 세로 스크롤만 검증. 창 크기 변경(줄바꿈 재배치)은 미해결.

11. 종합 벤치마크 (사전등록) — 5개 저장 정책의 연속 관찰 비교

[사전등록] 20에피소드×12관찰(값 갱신 68회) · 질문 200 × 정책 5 × 용량 2 · 성공 기준을 실행 전에 고정




읽는 법 — 실패 분석과 재실험의 기록

- 1차: 균등 배분은 8KB에서 전부 저장 실패(화면 최소 압축 크기 13.6KB > 한도). 제안은 저장에 성공했으나 전체 보관 대비 격차 4.0%p로 사전 기준(2%p) 미달 — 원인은 오래된 기억을 25% 면적 축소 이미지로 보관해 글자가 읽히지 않게 된 것.
- 2차: 보관 방식을 내용에 맞춰 변경(글자 화면 → 텍스트 변환 + 원크기 저품질 이미지), 조회된 기억은 삭제 순서에서 보호 → 8KB 0.640→0.935(+29.5%p), 24KB 0.955 = 전체 보관의 97.4%를 44%의 저장량으로. 저장-삭제 반복(진동) 0건.
- 조회 보호의 효과: 중간에 조회된 페이지 0.9605 vs 미조회 0.9194 (+4.1%p).
- 2차도 격차 2.5%p로 기준 미달 — 오답 9건 중 5건은 단위 누락('93' vs '93 min') 채점 문제. 기준을 사후 수정하지 않고 미달로 기록. *텍스트 정책은 완벽한 문자 인식을 가정.

12. 더 정교한 신호의 검증 — 추가 이득이 없음을 확인

[탐색] 시각 인코더의 표현 변화량(원본 대 압축본) 376장 + 운영 비용 예측



배분 개선 효과 (같은 총용량)

- GUI: +0.000 — 압축 가능 여부만으로 이미 이상적 배분에 도달, 개선 여지 없음
- 자연: +0.000 — 픽셀 통계·신호 조합에 이은 세 번째 부정 결과. 필요 용량은 이미지가 아니라 질문이 결정함이 확정.

운영 비용 실측 (V100 1장)

- 자연의 주원인 = 압축 품질 전수 탐색
10~12초/장 (이분 탐색으로 1초 수준 가능)
- 인코더 계산 0.23~2.4초/장,
메모리 17.5~29.6GB — 무료가 아님
- 질문 응답 경로에는 추가 부담 없음

읽는 법

- 사전학습된 시각 인코더로 '압축 후 모델이 보는 표현이 얼마나 변했나'를 재면 GUI에서 가장 정확한 예측기가 되지만(상관 0.89), 무료 신호가 이미 상한이라 실익이 없다.
- 자연 이미지에서는 예측 자체가 안 된다(0.51) — 세 번째 부정 결과로, 필요 용량은 질문이 결정한다는 결론이 확정. 유일한 대안은 질문 시점의 원본 재입력(5번 그림).
- 결론: 운영 비용까지 고려한 최선의 판단 재료 = 압축 시도의 성공/실패 + 픽셀 비교 (30ms) + 답변 확신도. 추가 학습·추가 모델·고가 신호는 불필요하거나 효과가 없다.

13. 전체 실험 목록 · 정정 사항 · 다음 단계

실패 · 정정 · 기준 미달 기록 포함

단계	실험 수	핵심	등급
0. 측정 신뢰	4건	수치 오류 근본해결 · 질문 정보 누출 4배 확인 · 저장 복원 검증	[검증]
1. 문서 예비 실험	5건	이상적 선택과 격차 38%p · 질문 전이 하락 40%p	[탐색]
2. GUI · 자연 확장	6건	근거 위치별 단계 하락 · 유형 3구분 · 허위 상관 합정 기록	[탐색]
3. 방법 후보	7건	확신도 감지 · 비용 실측 · 2번째 모델 재현 · 보존 비율 곡선	[탐색]
4. 확증 재현	6건	16회 반복 전 항목 같은 방향 · 공식 구현 비교	[확증]
5. 검토 · 정정	3건	선행연구 중복 확인 · 과장 표현 정정	[정정]
6. 진단 체계	7건	원본 접근 차단 검증 · 시간 · 행동 측 실험 · 설계 검토 8건	[검증~통제]
7. 저장 수단 비교	4건	32KiB 이미지 최선 · KV는 저장 부적격 확정	[완료]
8. 저장 관리 시스템	9건	용량 배분 +67% · 갱신 오류 48/48→1.0 · 종합 벤치마크 2회 · 신호 3중 부정	[통제~사전등록]

정정 · 미달 기록

- 정정 1: 이전 답 재활용의 '출력 동일 보장'은 과장이었음 (종료 토큰 미검증).
- 정정 2: '중요도 신호는 GUI에서 해롭다'는 자체 구현 한정 — 공식 KVzip은 GUI에서 최강.
- 선행 중복 확인: 진단 현상(SSF) · 압축-초안 검증(VeriCache) — 관련연구 위치 조정.
- 측정 주의: 시뮬레이션은 실제 파일 복원보다 +5%p 후함 → 시스템 수치는 복원 기준.
- 사전등록 기준 2회 연속 근소 미달(4.0/0.5%p)을 기준 수정 없이 기록 — 2차 미달분의 주원인은 채점의 단위 처리 문제.
- 용량 배분 이득의 원인 재규명: 예측 신호가 아니라 압축 가능 여부(+0.003만 신호 기여).

다음 단계

- 1) 채점 기준(단위 처리)을 명시한 3차 재판정 — 미달분이 채점 문제였으므로 통과 유력
- 2) 실제 앱 화면 기록에서의 최종 검증 — 부분 갱신 발동률 · 정렬 성능 실측 포함
- 3) 창 크기 변경(줄바꿈 재배치) 시의 변경 감지 — 마지막 미해결 문제
- 4) 논문 집필: 진단 → 갱신 오류 발견 → 시스템 설계 → 벤치마크 → 부정 결과 (학회 결정 대기)